

0722 회의록

전체 logic 정리

01) 파일 정리

1. DataCleansing.xlsx : 실제 분석 자료에 사용되는 파일명 (칼럼 정리 등)

- a. srcData : 형태를 정리한 전체 데이터
- b. 원본 독립변수 : 결측치 대체용
- c. 원본 종속변수
- d. before inputation : shuffle 후 임의 결측치에 구멍 뚫어놓은 데이터
- e. after_(모델명)
 - i. after_inputation_00 : 평균값 대체

2. DataChart.pdf : 데이터 시각화 결과

- a. 평균으로 대체했을 때와 모델을 사용했을 때의 차이 확인 가능

3. MissingData.pdf : 결측치 분포 시각화

- a. correlation, heatmap, boxplot 등

4. ResultData.xlsx : 예측 결과 데이터

- a. 차이점
 - i. 기존의 결측치였던 데이터를 빨간색으로 표시
 - ii. OneHot-Encoding 방식으로 대체
- b. Result Comparison : 개별 데이터별로 확인한 오차
- c. Result2_Method : 모델별로 요약 통계 정리
 - i. NRMSE, F1 Score

5. Analysis.pdf : 최종 결과 분석 데이터

- a. 칼럼별 모델별 NRMSE 시각화 결과 (오차가 가장 낮은 모델로 확정)
- b. 모델별로 몇 건 맞췄는지 → 최선의 모델 선정 가능하도록

02) 특이사항

- 평가 지표를 사용할 때, 맞췄는지 여부와 오차는 다른 개념이기에 의사결정 할 때에는 둘 다 참고해야함.
- 데이터는 굳이 3000개 이상 아니어도 O.
- 최종 output 형태
 - **web** (각자 url만으로도 가능하고, 서버만 바뀌도 모두 반영 가능)
 - application (버전마다 달라질 수 있기 때문에 유지 보수가 어려움)
- NAS 사용 가능 → 해당 PC에 웹서버 설치 후 돌아갈 수 있도록 작업
- Class2 에서 기포 콘크리트 데이터는 속성이 완전히 다르기 때문에 종속변수 예측에 영향을 미칠 수 있음. → 배제 예정
- 초기값 설정: numeric 데이터는 평균값으로, categorical 데이터는 최빈값으로 대체하는 것이 일반적.
- 평가지표

3. 결측치 대체 성과 계산

- 결측치 위치 식별 및 비교
 - `data_bf_imputation`의 결측치 위치를 식별
 - 각 위치에서 3가지 방법의 예측값과 실제값(`data_of_target`) 비교
- 가장 근접한 방법 분석
 - 각 결측치에 대해 가장 잘 맞춘 방법 식별
 - 방법별 정확도 및 맞춘 예측 개수 계산
 - 가장 잘 맞춘 방법과 가장 못 맞춘 방법 요약
- 오차율 계산
 - 연속형 데이터: NRMSE (Normalized Root Mean Squared Error)
 - 범주형/이진 데이터: PFC (Proportion of Falsely Classified entries)
 - 칼럼별로 각 방법의 오차율 계산
- F1 Score 계산
 - Precision, Recall, F1 Score 계산
 - 3가지 방법의 성능을 종합적으로 평가
- 결측치 성과 측정 기준의 정의

```
CONTINUOUS_TOLERANCE <- 0.01 # 5% 허용 오차
CONTINUOUS_ABSOLUTE_TOLERANCE <- 0.001 # 절대 허용 오차
```

- 오차범위를 0.01로 했을 때와 0.05로 했을 때 차이 발생 (best 성능 변화 : missforest → 1d-cnn)
- 다중공선성 문제 주의

03) 질문사항

- 오차범위를 칼럼별 표준편차를 분석한 것을 기반으로 하여 설정해보는 건 어떨지?
- 종속변수를 예측하는 데에 특별히 중요한 변수가 있는지?